УНИВЕРСИТЕТ ИТМО

Факультет прикладной информатики

Направление подготовки 09.03.03 Прикладная информатика

Образовательная программа «Мобильные и сетевые технологии»

Дисциплина «Автоматическая обработка текстов»

ОТЧЕТ по

лабораторной работе №6

«AI-детектив»

Автоматическая обработка текстов

Выполнили:

Генне Константин Валерьевич К3440,

Дедкова Анастасия Викторовна К3440,

Маракулин Андрей Андреевич К3441

Преподаватель:

Гусарова Н. Ф., доцент ФПИн, к.т.н.

Санкт-Петербург, 2026 г.

ВВЕДЕНИЕ

Цель работы — оценить, как одна языковая модель отвечает на вопросы по длинному вымышленному досье при полном контексте, поиске BM25 и p-adic организации тех же доказательств.

1 Подготовка данных для AI-детектива

Команда подготовила вымышленный сюжет и отдельно зафиксировала истинную последовательность событий. Этот закрытый файл не передавался модели.

14–15 марта 2026 года Илья и Даша вопреки запрету проводят ночное испытание прототипа «Нереида». После повреждения датчика они скрывают часть обстоятельств. Досье содержит и согласующиеся факты, и противоречивые свидетельства.

Суть инцидента: несанкционированное ночное испытание прототипа, нарушение регламента и допуска, авария с повреждением датчика, попытка сокрытия и ложные показания.

Досье включает восемь относящихся к расследованию и два нерелевантных документа, всего 5023 слова в полях text при подсчёте по пробелам. Все персонажи и события вымышлены.

Затем были подготовлены и выписаны утверждения. Для каждого утверждения проверены уникальность идентификатора, существование нужных документов и дословное присутствие evidence в соответствующем документе.

Подготовлены 12 вопросов шести типов, эталонные статусы и ID оснований. По сообщению участника команды от 17 октября 2026 года, все участники согласовали данные и 36 стресс-кейсов; личных подписей в файлах нет.

Подготовленные компоненты перечислены в таблице 1.

Таблица 1 – Состав подготовленных данных

Компонент	**Фактическое значение**
Релевантные документы	8 шт.
Нерелевантные документы	2 шт.
Общий объём досье	5023 слова
Атомарные утверждения	38 шт.
Вопросы	12 шт. по 2 каждого типа

Данные находятся в data/documents.jsonl, data/claims.jsonl, data/questions.jsonl и data/stress_cases.jsonl.

2 Организация контекста

В работе рассматривается 3 режима организации контекста для AI-детектива, перечисленные в таблице 2.

Таблица 2 – Режимы организации контекста

Режим	Состав контекста	Что проверяется
A – полный контекст	Все документы досье; порядок зафиксирован	Поведение модели при длинном контексте
B – плоский retrieval	До 15 утверждений, отобранных BM25	Эффект сокращения контекста
C – p-adic context	Те же 15 утверждений, что в B, сгруппированные по p-adic ветвям и времени	Эффект структурной организации контекста

2.1 Плоский retrieval

BM25 ранжирует утверждения по совпадению терминов вопроса и утверждения с учётом частоты слов в корпусе.

В режиме B модель получает не более 15 релевантных утверждений. Так проверяется эффект сокращения контекста.

2.2 P-adic организация доказательств

Используются $p = 3$ и путь $[a_0, a_1, a_2]$: тип источника, логический статус и время. Код пути $x = a_0 + 3a_1 + 9a_2$. Расстояние определяется длиной общего префикса, а не разностью кодов; при совпадении всех уровней оно равно нулю.

Тип источника стоит первым: системные записи, свидетельства и правила разделяются до статуса и времени. При другом порядке уровней изменилось бы соседство утверждений, а не состав извлечённых ID.

Для Q03 ветви отделяют системные записи C11 и C12, связывающие сеанс S17, идентификатор N7 и «Нереиду», от свидетельств. B и C получают один и тот же набор ID.

3 Стресс-тесты

Для каждого из 12 вопросов подготовлены три случая:

1) Перестановка документов с seed 42. Эталонный статус остаётся прежним;

2) Удаление посылки. В Q03–Q06 убрана необходимая посылка; в остальных восьми случаях удалён контрольный C13, не меняющий эталон;

3) Добавление противоречия. Создаются новый документ и утверждение от другого источника; эталон проверен отдельно для каждого вопроса.

Изменения внесены в stress_cases.jsonl. Сохраняются исходные и изменённые ID документов и утверждений; за один кейс меняется один фактор.

4 Исследовательский стенд

Реализован исследовательский стенд на базе Streamlit. В стенде предусмотрены загрузка досье, выбор вопроса и режима, просмотр ответа и confidence, просмотр доказательств и контрдоказательств, запуск стресс-тестов, просмотр p-adic ветвей и сравнение сохранённых результатов.

Для A, B и C использованы одна модель, один промпт и одинаковые параметры. B и C получают одинаковые claim_id; меняется их организация. Сырые ответы и переданные контексты сохранены.

Итоговый прогон 17 октября 2026 года: deepseek-flash, температура 0, max_tokens 1200, JSON Object, рассуждение отключено; системный промпт — prompts/system.txt. Получены все 144 ответа: 36 исходных и 108 стрессовых. Шесть ответов с пересечением evidence_ids и counterevidence_ids признаны невалидными и не перегенерированы.

5 Метрики и анализ

5.1 Основные метрики

Метрики исходных 12 вопросов в каждом режиме приведены в таблице 3. Точность статуса считает невалидные ответы ошибками. Остальные метрики рассчитаны по 10 валидным ответам A и 12 ответам B/C.

Таблица 3 – Результаты работы системы

Метрика	Что измеряет	Результат
Accuracy логического статуса	Доля вопросов с верно предсказанным статусом	A/B/C: 10/12 (83,3%)
Evidence precision	Доля найденных моделью доказательств, которые являются корректными	A/B/C: 1,00
Evidence recall	Доля эталонных доказательств, найденных моделью	A: 1,00; B/C: 0,39
Evidence F1	Гармоническое среднее precision и recall для доказательств	A: 1,00; B/C: 0,56
Counterevidence recall	Доля эталонных контрдоказательств, найденных моделью	A/B/C: 1,00
Точность распознавания both	Качество выявления одновременно подтверждающих и опровергающих оснований	A/B/C: 1,00 (recall, 2 вопроса)
Точность распознавания insufficient	Качество распознавания недостаточности данных	A/B/C: 1,00 (recall, 2 вопроса)
Уверенные ответы при недостатке данных	Доля случаев недостатка данных с неоправданно высокой уверенностью	A/B/C: 0,00
Токены и время ответа	Стоимость и скорость обработки	Входные токены A/B/C: 12 274 / 921 / 1117; время: 1,95 / 1,35 / 1,41 с

5.2 Измерение устойчивости посредством стресс-тестирования

В таблице 4 приведены только пары с валидными исходным и изменённым ответами.

Таблица 4 – Результаты стресс-тестирования

Тест	Ожидаемое поведение	Фактический результат
1. Перестановка документов	Эталонный ответ не меняется; зафиксировать, меняется ли ответ модели	32 валидные пары; статус изменился в 0/32, эталон получен в 28/32; evidence_ids совпали в 32/32.
2. Удаление посылки	Для Q03–Q06 ожидается insufficient; восемь удалений C13 — контроль.	34 валидные пары; статус изменился в 10/34, эталон получен в 31/34; у Q03–Q06 — 11/12 insufficient.
3. Добавление противоречия	Статус зависит от вопроса: для Q09–Q10 уже был both; Q11–Q12 остаются insufficient.	34 валидные пары; статус изменился в 16/34, эталон получен в 20/34; evidence_ids совпали в 23/34.

5.3 Ответы на исследовательские вопросы

1) Retrieval сократил средний вход с 12 274 до 921–1117 токенов, но не повысил точность статуса: во всех режимах 10/12. Evidence F1 у B/C составил 0,56 против 1,00 у валидных ответов A; поиск пропустил C09 в Q06 и часть оснований Q07.

2) На исходных противоречиях Q09–Q10 B и C дали both. Среди 47 валидных пар B/C при одинаковых ID статус различался в четырёх случаях; общего улучшения от группировки не видно.

3) На Q11–Q12 все режимы верно ответили insufficient без уверенной однозначной догадки. В B/C модель также ошибочно ответила insufficient на Q06 и Q07 из-за потери оснований.

4) После перестановки статус не изменился ни в одной из 32 валидных пар. В A контекст менялся, в B/C оставался прежним; для B/C влияние порядка документов этим тестом не измеряется.

5) Для четырёх удалений необходимой посылки Q03–Q06 статус insufficient получен в 11 из 12 ответов; C ошибся в Q04. Остальные восемь удалений были контрольными.

6) Средняя confidence среди валидных ответов — 0,72/0,62/0,62 в A/B/C. Их точность статуса — 1,00/0,83/0,83. На 12 вопросах этого недостаточно для вывода о калибровке уверенности.

7) После добавления противоречия C правильно дал both для Q07, B ответил contradicted. После удаления посылки Q04 B правильно дал insufficient, C — contradicted. Упаковка доказательств может помогать и мешать в отдельных случаях.

6 Вклад участников

Распределение задач и проверка данных отражены в таблице 5.

Таблица 5 – Вклад участников

Участник	Выполненная работа
Участник 1 Дедкова А.В.	Досье, утверждения, вопросы, эталоны и их проверка.
Участник 2 Генне К.В.	Проверка данных, BM25, p-adic организация, стресс-кейсы и тесты.
Участник 3 Маракулин А.А.	Проверка данных, LLM, интерфейс, метрики и тесты.

ЗАКЛЮЧЕНИЕ

Полный контекст и BM25 с p-adic организацией дали одинаковую точность статуса 10/12. Сокращение контекста уменьшило число токенов, но снизило полноту найденных доказательств. На добавленные противоречия модель реагировала хуже, чем на удаление посылки.

Ограничения: один вымышленный корпус, одна модель и один прогон; температура 0 не гарантирует повторяемости. Для Q08 рекомендательное разъяснение спорит с действующим регламентом, поэтому статус источников неодинаков. Выводы не распространяются на другие модели и корпуса.