УНИВЕРСИТЕТ ИТМО

Факультет прикладной информатики

Направление подготовки 09.03.03 Прикладная информатика

Дисциплина «Автоматическая обработка текстов»

Отчёт по лабораторной работе № 6

AI детектив

Сравнение полного контекста, BM25 и p-adic организации доказательств

Выполнили:

Генне Константин Валерьевич, К3440

Дедкова Анастасия Викторовна, К3440

Маракулин Андрей Андреевич, К3441

Преподаватель: Гусарова Н. Ф.

Санкт-Петербург, 2026

Цель и данные

Цель работы — проверить ответы одной языковой модели на вопросы по длинному вымышленному досье с разнесёнными фактами, временными условиями, правилами, противоречиями и недостатком данных. Сравниваются полнота контекста, поиск утверждений и организация одного и того же результата поиска.

Досье «Ночной сеанс Нереиды» содержит 10 документов и 5023 слова в полях text при подсчёте по пробелам, 38 атомарных утверждений и 12 вопросов — по два каждого из шести типов. Подготовлены 36 стресс-кейсов: по 12 перестановок, удалений и добавлений противоречия. По сообщению участника команды от 17 октября 2026 года, эталоны и кейсы согласованы всеми участниками. Закрытая авторская последовательность событий не передавалась модели; эталоны основаны на открытом досье.

Протокол

Режим A передаёт все документы в фиксированном порядке и реестр ID утверждений. Режим B выбирает BM25 top-15; режим C передаёт те же ID, группируя их по p-adic пути $[a_0,a_1,a_2]$ при $p = 3$ и сортируя по времени внутри ветви. Тип источника стоит первым, чтобы разделить системные записи, свидетельства и правила до учёта статуса и времени; при другом порядке уровней соседство утверждений изменилось бы.

Во всех режимах использованы deepseek-flash, один системный промпт (prompts/system.txt), температура 0, max_tokens 1200, JSON Object и отключённое рассуждение. Выполнены 144 вызова. Сохранены полный переданный контекст, параметры, сырой ответ, токены и время. Шесть ответов нарушили правила формата или ссылок; их не перегенерировали и считают ошибками статуса. Все 144 контекста повторно сопоставлены с текущими данными.

Результаты без стресс-тестов

Метрика	A	B	C
Верный статус / все 12	10/12	10/12	10/12
Валидных ответов	10/12	12/12	12/12
Evidence precision	1,00	1,00	1,00
Evidence recall	1,00	0,39	0,39
Evidence F1	1,00	0,56	0,56
Counterevidence recall	1,00	1,00	1,00
Recall both / insufficient	1,00 / 1,00	1,00 / 1,00	1,00 / 1,00
Уверенная догадка при insufficient	0,00	0,00	0,00
Средняя confidence	0,72	0,62	0,62
Входные токены, среднее	12274	921	1116
Время, с, среднее	1,95	1,35	1,41

Точность статуса учитывает все 12 ответов каждого режима, включая невалидные как ошибки. Метрики доказательств, confidence, токенов и времени рассчитаны только по валидным ответам: 10 в A и по 12 в B/C. Для исходных both и insufficient всего по два вопроса, поэтому recall 1,00 нельзя считать устойчивой оценкой.

Стресс-тесты

Изменение	Валидных пар	Статус изменился	Ожид. статус	ID стабильны
Перестановка	32	0%	88%	100%
Удаление	34	29%	91%	79%
Противоречие	34	47%	59%	68%

Пары учитываются только при валидных исходном и изменённом ответах. Перестановка не изменила статус ни в одной из 32 пар; в A текст контекста менялся, а в B/C оставался одинаковым, поэтому результат B/C не измеряет влияние порядка документов. Для четырёх удалений необходимой посылки Q03–Q06 ожидаемый insufficient получен в 11 из 12 ответов; C ошибся на Q04. Остальные восемь удалений — контрольные.

После добавления противоречия ожидаемый статус получен в 20 из 34 валидных пар. У Q09–Q10 исходно уже был both; у Q11–Q12 конфликт касался вспомогательного факта, и эталон остался insufficient. В Q08 новое рекомендательное разъяснение спорит с действующим регламентом, поэтому равный вес источников является ограничением этого кейса.

Ответы на исследовательские вопросы

Retrieval сократил средний вход с 12 274 до 921–1117 токенов, но не повысил точность статуса: во всех режимах 10/12. Evidence F1 у B/C составил 0,56 против 1,00 у валидных ответов A. Поиск пропустил C09 в Q06 и несколько оснований правила в Q07; модель B/C ответила insufficient.

P-adic группировка не улучшила исходные противоречия Q09–Q10: B и C ответили both. На 47 валидных парах B/C при одинаковых ID статусы различались в четырёх случаях. В Q07 после добавления противоречия C получил эталонный both, а B — contradicted; в Q04 после удаления посылки B верно ответил insufficient, а C — contradicted. Это примеры возможной пользы и вреда упаковки, а не доказательство общего эффекта.

На Q11–Q12 модель во всех трёх режимах отказалась от недоказанного вывода, без уверенных однозначных догадок. Средняя confidence среди валидных ответов составила 0,72/0,62/0,62 при доле верных статусов 1,00/0,83/0,83; на таком малом наборе это не доказывает калибровку. После удаления необходимой посылки ответ обычно становился insufficient, а на добавленные противоречия реакция была заметно слабее.

Вывод и ограничения

На одном вымышленном досье и одной модели сокращение контекста существенно уменьшило число токенов, но снизило полноту доказательств. Группировка p-adic не дала преимущества на исходных вопросах и по-разному влияла на отдельные стресс-кейсы. Шесть структурно ошибочных ответов и неудачная обработка части противоречий показывают, почему поиск, организацию контекста и генерацию нужно оценивать раздельно. Повторов одинакового запроса не было; температура 0 не гарантирует полной повторяемости, а причинный эффект порядка для B/C установить нельзя.

Дедкова А. В. подготовила досье, утверждения, вопросы и эталоны; Генне К. В. проверил данные и реализовал BM25, p-adic организацию и стресс-кейсы; Маракулин А. А. интегрировал LLM, интерфейс, метрики и тесты. Эпизоды работы с ИИ и ручной проверки описаны в AI_LOG.md.