AI-детектив: результаты лабораторной работы 6

Модель: deepseek-flash. В полном прогоне: 12 вопросов × 3 режима и 28 стресс-кейсов × 3 режима. Во всех режимах использован один системный промпт и одинаковые параметры. B и C получали одинаковые ID утверждений; в C менялась только их организация.

Основные метрики

Режим	Статус	Evidence F1	Both recall	Insuff. recall	Токены ввода
A	0.67	1.00	1.00	1.00	12200.25
B	0.67	0.54	1.00	1.00	862.10
C	0.67	0.52	1.00	1.00	1029.91

На этих 12 вопросах максимальная точность статуса у режима(ов) A, B, C (0.67). Retrieval B относительно полного текста A: 0.67 против 0.67. p-adic C относительно B: 0.67 против 0.67. Разница описательная; выборка мала и не доказывает общего преимущества метода.

Противоречия, неизвестность и уверенность

Recall статуса both: A 1.00, B 1.00, C 1.00. Recall insufficient: A 1.00, B 1.00, C 1.00. Доля уверенных однозначных ответов там, где эталон insufficient: A 0.00, B 0.00, C 0.00. Средняя confidence и фактическая точность: A 0.64/1.00, B 0.57/0.80, C 0.59/0.73.

Невалидных по логическим правилам ответов: A: 4 из 12; B: 2 из 12; C: 1 из 12. В точности статуса по всем вопросам они считаются ошибками; остальные метрики вычислены по валидным ответам.

Evidence precision/recall и recall контрдоказательств: A: 1.00/1.00, counter 1.00; B: 0.88/0.39, counter 0.75; C: 0.78/0.39, counter 0.60. Среднее время ответа и токены вывода: A: 1.74 с, 125.12; B: 1.26 с, 109.10; C: 1.25 с, 108.91.

Стресс-тесты

Перестановка документов: 26 валидных пар ответов; изменился статус в доле 0.04, ожидаемая реакция получена в доле 0.81, доказательства сохранились в доле 0.96.

Удаление посылки: 10 валидных пар ответов; изменился статус в доле 0.80, ожидаемая реакция получена в доле 0.90, доказательства сохранились в доле 0.20.

Добавление противоречия: 27 валидных пар ответов; изменился статус в доле 0.56, ожидаемая реакция получена в доле 0.70, доказательства сохранились в доле 0.70.

Между flat и p-adic статус различается в доле 0.16 пар; одинаковый набор ID в B/C: да. Тип источника поставлен первым уровнем p-adic пути, чтобы сначала разделить системные записи, свидетельства и правила; при ином порядке уровней соседство утверждений и форма контекста изменились бы.

Примеры, где C помог относительно B: Q02; где C ухудшил статус: Q05.

Ограничения и вклад

Эксперимент проведён на одном вымышленном досье и одной модели. Метрики относятся к этим 12 вопросам и подготовленным изменениям; они не измеряют причинный эффект группировки за пределами данного набора. Дедкова: досье и эталоны; Генне: retrieval, p-adic, контекст и стресс-подготовка; Маракулин: LLM, интерфейс, метрики и интеграционные тесты.