УНИВЕРСИТЕТ ИТМО

Факультет прикладной информатики

Направление подготовки 09.03.03 Прикладная информатика

Образовательная программа «Мобильные и сетевые технологии»

Дисциплина «Автоматическая обработка текстов»

ОТЧЕТ по

лабораторной работе №6

«AI-детектив»

Выполнили:

Генне Константин Валерьевич К3440,

Дедкова Анастасия Викторовна К3440,

Маракулин Андрей Андреевич К3441

Преподаватель:

Гусарова Н. Ф., доцент ФПИн, к.т.н.

Санкт-Петербург, 2026 г.

ВВЕДЕНИЕ

Цель работы: исследовать поведение языковой модели при ответах на вопросы по длинному тексту, содержащему разнесенные факты, временные зависимости, правила, исключения, противоречия, нерелевантную информацию и вопросы без однозначного ответа.

1 Подготовка данных для AI-детектива

Первым делом командой был придуман сюжет инцидента и зафиксирована истинная последовательность событий в отдельном файле.

Кратко приведем сюжет. 14–15 марта 2026 года после дневной отмены испытаний двое участников команды Илья и Даша тайно проводят ночной водный запуск прототипа беспилотного катера «Нереида» в бассейне. Илья использует легальный доступ для проверки зарядного шкафа, чтобы загрузить новую версию программы и вывезти аппарат. Испытание заканчивается столкновением катера с лестницей и повреждением бокового датчика. Аппарат возвращают в мастерскую, участники договариваются скрывать случившееся до утра. Утром третий участник команды Соня обнаруживает новую версию программы и следы ночного сеанса.

Суть инцидента: несанкционированное ночное испытание прототипа, нарушение регламента и допуска, авария с повреждением датчика, попытка сокрытия и ложные показания.

Следующим шагом с помощью LLM были сгенерированы документы для досье, и в них добавлены противоречия. Досье также было дополнено нерелевантными документами. Все персонажи, события и цифровые объекты в досье являются вымышленными. Документы раскрывают отдельные части последовательности событий, чтобы для ответа на часть вопросов требовалось сопоставлять несколько источников. Все документы были вручную проверены.

Затем были подготовлены и выписаны утверждения. Для каждого утверждения проверены уникальность идентификатора, существование нужных документов и дословное присутствие evidence в соответствующем документе.

Составлены вопросы, эталонные ответы к ним и их статусы. Было проверено, что существуют нужные для подтверждения/опровержения утверждения.

Подготовленные компоненты перечислены в таблице 1.

Таблица 1 – Состав подготовленных данных

Компонент	**Фактическое значение**
Релевантные документы	8 шт.
Нерелевантные документы	2 шт.
Общий объем досье	5029 слов
Атомарные утверждения	37 шт.
Вопросы	12 шт. по 2 каждого типа

Данные хранятся в файлах documents.jsonl, claims.jsonl и questions.jsonl.

2 Организация контекста

В работе рассматривается 3 режима организации контекста для AI-детектива, перечисленные в таблице 2.

Таблица 2 – Режимы организации контекста

Режим	Состав контекста	Что проверяется
A – полный контекст	Все документы досье; порядок зафиксирован	Поведение модели при длинном контексте
B – плоский retrieval	До 15 утверждений, отобранных BM25	Эффект сокращения контекста
C – p-adic context	Те же 15 утверждений, что в B, сгруппированные по p-adic ветвям и времени	Эффект структурной организации контекста

2.1 Плоский retrieval

BM25 – алгоритм поиска текстовых фрагментов по релевантности запросу. Он оценивает соответствие документа запросу с учетом частоты встречаемости терминов и их распространенности в коллекции документов.

В данной работе BM25 используется для отбора 15 наиболее релевантных атомарных утверждений из досье. Отобранные утверждения передаются языковой модели в виде плоского списка. Такой подход позволяет сократить объем контекста и проверить, насколько эффективно модель отвечает на вопросы при использовании только наиболее релевантной информации.

2.2 P-adic организация доказательств

Для организации утверждений используется $p = 3$ и путь $[a_0, a_1, a_2]$, которому соответствует код $x = a_0 + a_1 \cdot 3 + a_2 \cdot 3^2$. Уровень a_0 описывает тип источника, a_1 – логический статус, a_2 – временное положение относительно события. Расстояние определяется по числу совпадающих начальных уровней: если совпадает k начальных уровней, $d_3(x,y) = 3^{-k}$; при полном совпадении пути расстояние в рамках работы принимается равным нулю.

Порядок уровней выбран так, чтобы тип источника учитывался раньше логического статуса и времени. Это отражает принятую в эксперименте иерархию организации доказательств: сначала различается происхождение сведений, затем характер утверждения, затем его временная привязка. При другом порядке уровней соседство и группировка утверждений изменились бы, поэтому модель могла бы получать иной структурированный контекст.

Приведем пример для Q03. В базовом режиме для вопроса «Верно ли, что ночной сеанс S17 относится к прототипу „Нереида“?» получено пять p-adic ветвей, объединяющих утверждения по типу источника, логическому статусу и времени:

1) [0, 0, 0] – системные установленные факты до события: C04, C11, C16, C13. Содержат сведения о загрузке программы на «Нереиду», идентификаторе N7 и начале сеанса S17;

2) [0, 0, 1] – системные подтвержденные факты во время события: C14, C37. Описывают отправку команды устройством T2 и срабатывание датчика удара;

3) [0, 0, 2] – системные подтвержденные факты после события или с неизвестной временной привязкой: C01, C12, C15, C33, C34. В частности, C12 связывает идентификатор N7 с прототипом «Нереида», а C11 указывает этот идентификатор в поле «устройство» сеанса S17;

4) [1, 1, 2] – свидетельства и предположения: C29, C30. Содержат сведения о состоянии прототипа и установке новой программы;

5) [1, 2, 0] – спорные свидетельства: C27, C28. Отражают противоречащие друг другу заявления о том, знала ли Марина о планируемом ночном испытании.

3 Стресс-тесты

Для вопросов составлены три стресс-теста:

1) Перестановка документов. Случайным образом изменен порядок документов с зафиксированным random_state;

2) Удаление посылки. Для multi-hop и временных вопросов удалено одно необходимое утверждение. Подразумевается, что статус должен измениться на insufficient либо both, если сохраняются конфликтующие основания;

3) Добавление противоречия. К каждому вопросу приложено несовместимое утверждение от другого сгенерированного источника. Если оснований выбрать один источник нет, ожидается переход к both.

Все стресс-тесты заранее описаны в файле stress_cases.jsonl.

4 Исследовательский стенд

Реализован исследовательский стенд на базе Streamlit. В стенде предусмотрены загрузка досье, выбор вопроса и режима, просмотр ответа и confidence, просмотр доказательств, запуск стресс-тестов, просмотр p-adic ветвей и сравнение сохраненных результатов.

Для всех режимов используется одна и та же LLM, одинаковый системный промпт и одинаковые параметры генерации. В режимах B и C совпадает набор claim_id; меняется только организация контекста. Ответы сохраняются до ручного анализа.

Параметры запуска:

1) модель – deepseek-V4-flash;

2) температура – 0;

3) остальные параметры – max_tokens 1200, JSON Object, рассуждение отключено;

4) промпт – prompts/system.txt.

5 Метрики и анализ

5.1 Основные метрики

Результаты работы системы во всех трех режимах без стресс-тестов приведены в таблице 3.

Таблица 3 – Результаты работы системы

Метрика	Что измеряет	Результат
Accuracy логического статуса	Доля вопросов с верно предсказанным статусом	A: 0,75; B: 0,83; C: 0,83
Evidence precision	Доля найденных моделью доказательств, которые являются корректными	A: 0,78; B: 1,00; C: 1,00
Evidence recall	Доля эталонных доказательств, найденных моделью	A: 0,64; B: 0,37; C: 0,37
Evidence F1	Гармоническое среднее precision и recall для доказательств	A: 0,70; B: 0,54; C: 0,54
Countereviden ce recall	Доля эталонных контрдоказательств, найденных моделью	A: 0,62; B: 0,75; C: 0,75
Точность распознавани я both	Качество выявления одновременно подтверждающих и опровергающих оснований	A: 1,00; B: 1,00; C: 1,00
Точность распознавани я insufficient	Качество распознавания недостаточности данных	A: 1,00; B: 1,00; C: 1,00
Уверенные ответы при недостатке данных	Доля случаев недостатка данных с неоправданно высокой уверенностью (confidence ≥ 0,80)	A: 0,00; B: 0,00; C: 0,00
Токены и время ответа	Среднее количество входных токенов и средняя скорость обработки одного ответа	A: 12239 токенов; 1,83 с; B: 904 токенов; 1,26 с; C: 1077 токенов; 1,25 с

5.2 Измерение устойчивости посредством стресс-тестирования

Также проведено измерение устойчивости с использованием стресс-тестов, результаты приведены в таблице 4.

Таблица 4 – Результаты стресс-тестирования (Д – доказательства, КД – контрдоказательства)

Тест	Режим	Ожидаемое поведение	Фактический результат
1. Перестановка документов	A	Эталонный ответ не меняется	Валидных ответов: 11/12. Верно: 11/11. Изменение: 2/11, оба изменения исправили исходные ошибки. Стабильность Д: 9/11, КД: 9/11.
	B		Валидных ответов: 11/12. Верно: 9/11. Изменение: 0/11. Стабильность Д: 11/11, КД: 11/11.
	C		Валидных ответов: 12/12. Верно: 10/12. Изменение: 0/12. Стабильность Д: 12/12, КД: 11/12.
2. Удаление посылки	A	Статус меняется на insufficient либо both, если остаются конфликтующие основания	Валидных ответов: 11/12. Верно: 11/11. Изменение: 4/11. Стабильность Д: 8/11, КД: 10/11.
	B		Валидных ответов: 12/12. Верно: 11/12. Изменение: 3/12. Стабильность Д: 10/12, КД: 11/12.
	C		Валидных ответов: 12/12. Верно: 10/12. Изменение: 3/12. Стабильность Д: 10/12, КД: 9/12.
3. Добавление противоречия	A	При отсутствии основания предпочесть один источник ожидается both	Валидных ответов: 11/12. Верно: 7/11. Изменение: 4/11. Стабильность Д: 8/11, КД: 3/11.
	B		Валидных ответов: 12/12. Верно: 6/12. Изменение: 5/12. Стабильность Д: 11/12, КД: 4/12.
	C		Валидных ответов: 12/12. Верно: 9/12. Изменение: 5/12. Стабильность Д: 10/12, КД: 4/12.

5.3 Ответы на исследовательские вопросы

1) Улучшает ли retrieval результат по сравнению с полным текстом?

Retrieval увеличил точность определения статуса с 9/12 до 10/12, сократив вход с 12 239 до 904–1077 токенов. Однако метрика Evidence F1 снизилась с 0,70 до 0,54, что математически обусловлено снижением полноты (Evidence recall: с 0,64 до 0,37) при сохранении максимальной точности найденных доказательств (Evidence precision: 1,00).

2) Улучшает ли p-adic группировка распознавание противоречий?

Наблюдается положительная тенденция. При искусственном добавлении противоречия режим C дал верный ответ в 9 из 12 случаев, тогда как режим B – только в 6 из 12. При этом в обычных условиях (таблица 3) точность распознавания both у B и C одинакова (1,00).

3) Отличает ли модель insufficient от правдоподобной догадки?

Да. Точность распознавания insufficient во всех режимах равна 1,00, а доля уверенных ответов при недостатке данных – 0,00. Это означает, что модель не подменяет отсутствие информации правдоподобными догадками.

4) Меняется ли ответ после перестановки документов?

В режиме полного контекста ответы чувствительны к порядку: изменились 2 ответа из 11 (18%), причем оба изменения исправили исходные ошибки.

5) Как модель реагирует на удаление необходимой посылки?

Модель адекватно реагирует на удаление: в режиме A 4 изменения из 11 (все верные), в B – 3 из 12 (11 верных), в C – 3 из 12 (10 верных). Удаление должно было по задумке повлиять на multi-hop и временные вопросы, которых в сумме 4. Ожидаемый переход в insufficient или both происходит в большинстве случаев.

6) Соответствует ли confidence фактической точности?

Средняя уверенность модели на валидных исходных ответах составила 0,75 в режиме A и 0,62 в режимах B и C, тогда как фактическая точность на

тех же ответах – 0,75, 0,83 и 0,83 соответственно. В режиме A средние значения совпадают, а в режимах B и C confidence ниже наблюдаемой точности. Это указывает на отсутствие переуверенности и на общую тенденцию модели к осторожной оценке своих ответов, особенно при использовании retrieval.

7) В каких случаях p-adic структура помогает, а в каких мешает?

P-adic структура (режим C) помогает при распознавании противоречий: в тесте 3 она дала 9 верных ответов против 6 у плоского retrieval. Это согласуется с предположением, что явная группировка утверждений по типу источника, логическому статусу и времени помогает модели учитывать статус источников и замечать конфликты. В то же время в тесте 2 (удаление посылки) C немного уступает B (10 верных против 11). Таким образом, p-adic организация полезна для задач, где важны логические статусы и временные зависимости (особенно противоречия), но может быть избыточной или незначительно мешать в простых сценариях, где плоский список доказательств достаточен.

6 Вклад участников

Вклад каждого участника команды представлен в таблице 5.

Таблица 5 – Вклад участников

Участник	Выполненная работа
Участник 1 Дедкова А.В.	Составление досье, утверждений, вопросов, эталонов и их проверка
Участник 2 Генне К.В.	Проверка данных, реализация BM25, p-adic организация и построение контекста, составление автоматических тестов для соответствующих функций
Участник 3 Маракулин А.А.	Проверка данных, LLM, интерфейс, метрики и составление автоматических тестов для соответствующих функций

ЗАКЛЮЧЕНИЕ

В ходе лабораторной работы была исследована способность LLM отвечать на вопросы по длинному досье, в котором сведения распределены по нескольким документам, могут зависеть от временного порядка, содержать исключения и противоречия либо не давать достаточных оснований для однозначного ответа. Для решения задачи используются атомарные утверждения с привязкой к исходным источникам, эталонные логические статусы и ссылки на доказательства и контрдоказательства.

Сравнение режимов показывает, что сокращение контекста с помощью retrieval повышает точность логического статуса и доказательств, тогда как полный контекст сохраняет преимущество в полноте охвата эталонных оснований. P-adic-организация не дает систематического выигрыша по основным метрикам, но в стресс-сценарии с добавлением противоречия выглядит предпочтительнее плоского retrieval, что согласуется с предположением о пользе явной группировки утверждений по типу источника, статусу и времени, однако этот эффект может объясняться и вспомогательными метками ветвей. При удалении необходимой посылки модель в большинстве случаев корректно переходит к insufficient или both, хотя единичные пропуски сохраняются. Добавление противоречия остается наиболее сложным испытанием: модель не всегда уверенно выбирает между конфликтующими источниками, но при недостатке данных не подменяет вывод правдоподобной догадкой и не демонстрирует неоправданно высокой уверенности.

ПРИЛОЖЕНИЕ А

Ссылка на репозиторий проекта на GitHub

https://github.com/KosGeny/ai-detective